

Aula 3
Introdução ao
Python - Parte III - NumPy

Introdução

- O *Numerical Python* (*NumPy*) é um pacote para a linguagem Python que suporta *arrays* e matrizes multidimensionais
- Além disso, possui uma série de funções para realizar operações matemáticas envolvendo essas estruturas
- Além das funções, também possui uma série de *sugar syntaxes*, a qual permite usar operadores matemáticas para fazer operações em matrizes e arrays

Introdução

- Outras razões da popularização do NumPy são:
 - Sintaxe e funções semelhantes ao *software* proprietário Matlab
 - Velocidades de processamento (2x mais rápido que o processamento em listas)
 - É utilizado em outras bibliotecas famosas como a OpenCV (visão computacional), Keras (*deep learning*) e o Scikit-Learn (aprendizado de máquina)
 - Aproximadamente 450 bibliotecas utilizam o NumPy

Importando

- Para utilizar o NumPy deve-se importar o pacote numpy
- Normalmente utiliza-se o alias np
- Portanto:

```
In [1]: import numpy as np
```

Inicializando

- O NumPy provê várias funções para criar *arrays*
- A mais comum delas é a função `array`
- Essa função recebe uma lista, lista de listas, e assim por diante, e retorna uma *array* multidimensional da biblioteca NumPy

```
In [2]: integers = np.array([[1,2,3], [4,5,6]])
```

```
In [3]: integers
```

```
Out[3]: array([[1, 2, 3],  
               [4, 5, 6]])
```

```
In [4]: floats = np.array([0.0, 0.1, 0.2, 0.3, 0.4])
```

```
In [5]: floats
```

```
Out[5]: array([0. , 0.1, 0.2, 0.3, 0.4])
```

Inicializando

• Outras formas comuns de inicializar são:

```
In [2]: 1 #inicializando array com zeros
        2 arr_zeros1 = np.zeros(10)
        3 arr_zeros1
```

```
Out[2]: array([0., 0., 0., 0., 0., 0., 0., 0., 0., 0.])
```

```
In [4]: 1 #inicializando array com zeros (bidimensional)
        2 arr_zeros2 = np.zeros((2,5))
        3 arr_zeros2
```

```
Out[4]: array([[0., 0., 0., 0., 0.],
               [0., 0., 0., 0., 0.]])
```

```
In [5]: 1 #inicializando com um range de valores
        2 arr_range = np.arange(10)
        3 arr_range
```

```
Out[5]: array([0, 1, 2, 3, 4, 5, 6, 7, 8, 9])
```

```
In [7]: 1 arr_empty = np.empty(10)
        2 arr_empty
```

```
Out[7]: array([6.93924935e-310, 6.93924935e-310, 0.00000000e+000, 0.00000000e+000,
               0.00000000e+000, 0.00000000e+000, 0.00000000e+000, 0.00000000e+000,
               0.00000000e+000, 0.00000000e+000])
```

```
In [8]: 1 #inicializando um array com valores 5 linearmente espaçados entre 1 e 50
        2 arr_lin = np.linspace(1,50, 5)
        3 arr_lin
```

```
Out[8]: array([ 1. , 13.25, 25.5 , 37.75, 50.  ])
```

```
In [9]: 1 #inicializando um array com 5 inteiros aleatório de 0 a 10
        2 arr_rand_int = np.random.randint(10,size=5)
        3 arr_rand_int
```

```
Out[9]: array([3, 9, 7, 2, 0])
```

Atributos

- Os objetos possui uma série de atributos para descrever o conteúdo armazenado

```
In [6]: integers.dtype #Retorna o tipo de dado armazenado no vetor
```

```
Out[6]: dtype('int64')
```

```
In [7]: floats.dtype
```

```
Out[7]: dtype('float64')
```

```
In [8]: integers.ndim #Nº de dimensões
```

```
Out[8]: 2
```

```
In [10]: integers.size # Total de elementos armazenados
```

```
Out[10]: 6
```

```
In [11]: floats.ndim
```

```
Out[11]: 1
```

```
In [12]: floats.size
```

```
Out[12]: 5
```

```
In [13]: integers.shape #Tupla contendo o nº de linhas e colunas
```

```
Out[13]: (2, 3)
```

```
In [14]: floats.shape
```

```
Out[14]: (5,)
```

Atributos

- Vale ressaltar que é possível alterar os atributos de um array
- O mais comum e requerido por muitas aplicações é alterar o *shape* do array
- Por exemplo, se você possui um vetor mas a função só aceita uma matriz, é possível alterar o shape $(x,)$ para $(x,1)$
- O reshape só pode ser aplicado se o número de dimensões continuar o mesmo

Atributos

```
In [21]: 1 #criando um array unidimensional  
2 array1 = np.arange(15)  
3 array1
```

```
Out[21]: array([ 0,  1,  2,  3,  4,  5,  6,  7,  8,  9, 10, 11, 12, 13, 14])
```

```
In [22]: 1 array1.shape
```

```
Out[22]: (15,)
```

```
In [23]: 1 #retornado o array1 com shape de 3 linhas e 5 colunas  
2 array1.reshape(3,5)
```

```
Out[23]: array([[ 0,  1,  2,  3,  4],  
                [ 5,  6,  7,  8,  9],  
                [10, 11, 12, 13, 14]])
```

```
In [24]: 1 #retornado o array1 com shape de uma linha e 5 colunas  
2 array1.reshape(1,15)
```

```
Out[24]: array([[ 0,  1,  2,  3,  4,  5,  6,  7,  8,  9, 10, 11, 12, 13, 14]])
```

```
In [25]: 1 #mesmo efeito da célula acima  
2 array1.reshape(1,-1)
```

```
Out[25]: array([[ 0,  1,  2,  3,  4,  5,  6,  7,  8,  9, 10, 11, 12, 13, 14]])
```

Atributos

- Em caso de um `reshape` em um `array` multidimensional, pode-se especificar a ordem em que os elementos do `array` original serão percorridos para gerar o novo `array`

```
In [21]: 1 #criando um array unidimensional
          2 array1 = np.arange(15)
          3 array1
```

```
Out[21]: array([ 0,  1,  2,  3,  4,  5,  6,  7,  8,  9, 10, 11, 12, 13, 14])
```

```
In [22]: 1 array1.shape
```

```
Out[22]: (15,)
```

```
In [23]: 1 #retornado o array1 com shape de 3 linhas e 5 colunas
          2 array1.reshape(3,5)
```

```
Out[23]: array([[ 0,  1,  2,  3,  4],
                 [ 5,  6,  7,  8,  9],
                 [10, 11, 12, 13, 14]])
```

```
In [24]: 1 #retornado o array1 com shape de uma linha e 5 colunas
          2 array1.reshape(1,15)
```

```
Out[24]: array([[ 0,  1,  2,  3,  4,  5,  6,  7,  8,  9, 10, 11, 12, 13, 14]])
```

```
In [25]: 1 #mesmo efeito da célula acima
          2 array1.reshape(1,-1)
```

```
Out[25]: array([[ 0,  1,  2,  3,  4,  5,  6,  7,  8,  9, 10, 11, 12, 13, 14]])
```

Acesso aos elementos

- O acesso ao elemento de um *array* é o mesmo do acesso à um elemento de uma lista

```
In [3]: grades = np.array([[87, 96, 70],  
                           [100, 87, 90],  
                           [94, 77, 90],  
                           [100, 81, 82]])
```

```
In [4]: grades
```

```
Out[4]: array([[ 87,  96,  70],  
               [100,  87,  90],  
               [ 94,  77,  90],  
               [100,  81,  82]])
```

```
In [5]: grades[1]
```

```
Out[5]: array([100,  87,  90])
```

```
In [6]: grades[0,1]
```

```
Out[6]: 96
```

Acesso aos elementos

- Operações de *slicing* também podem ser utilizadas

```
In [7]: #Retornando as duas primeiras linhas do array  
grades[0:2]
```

```
Out[7]: array([[ 87,  96,  70],  
              [100,  87,  90]])
```

```
In [8]: #Retornado as linhas 1 e 3 do array  
grades[[1,3]]
```

```
Out[8]: array([[100,  87,  90],  
              [100,  81,  82]])
```

```
In [10]: """Retornando a primeira coluna das 3 primeiras  
          linhas do array"""  
grades[0:3,0]
```

```
Out[10]: array([ 87, 100,  94])
```

Acesso aos elementos

```
In [11]: #Selecionando tudo menos a última coluna  
grades[:,0:-1]
```

```
Out[11]: array([[ 87,  96],  
                [100,  87],  
                [ 94,  77],  
                [100,  81]])
```

```
In [12]: grades[:, -1] #Selecionando só a última coluna
```

```
Out[12]: array([70, 90, 90, 82])
```

```
In [14]: #Especificando as colunas utilizando uma lista  
grades[:, [0, -1]]
```

```
Out[14]: array([[ 87,  70],  
                [100,  90],  
                [ 94,  90],  
                [100,  82]])
```

Acesso aos elementos

- Também é possível passar um *array* de booleanos no índice, e todos os respectivos elementos cuja respectivo valor no *array* booleano for true serão retornados

```
In [45]: 1 array1 = np.random.randint(50, size=10)
          2 array1
```

```
Out[45]: array([33, 18, 44, 13,  6, 28, 40, 40, 17, 30])
```

```
In [46]: 1 array1[[True, False, True, True, False, False, True, True, False, False]]
```

```
Out[46]: array([33, 44, 13, 40, 40])
```

```
In [47]: 1 resultado = array1 > 10
          2 resultado
```

```
Out[47]: array([ True,  True,  True,  True, False,  True,  True,  True,  True,
                True])
```

```
In [48]: 1 array1[resultado]
```

```
Out[48]: array([33, 18, 44, 13, 28, 40, 40, 17, 30])
```

Percorrendo os Arrays

- Arrays são iteráveis, e, portanto, pode-se aplicar a estrutura `for` considerando essas estruturas

```
In [18]: for linha in integers:  
        for elemento in linha:  
            print(elemento, sep=' ', end=' ')  
        print()
```

```
1 2 3  
4 5 6
```

```
In [21]: for elemento in floats:  
        print(elemento, sep=' ', end=' ')
```

```
0.0 0.1 0.2 0.3 0.4
```

Operações

- Uma das principais características do NumPy e que o aproximam de outros *softwares* proprietários, é a **facilidade de se realizar operações matemáticas** utilizando a estruturas de *arrays*
- Além da facilidade das operações matemáticas, operações de **comparação, transposição e sumarização** dos dados também podem ser realizadas com facilidade

Operações entre Escalar e Array

```
In [22]: #Gerando um array de numeros inteiros de 1 a 4  
numbers = np.arange(1,5)
```

```
In [23]: numbers
```

```
Out[23]: array([1, 2, 3, 4])
```

```
In [68]: 5 * numbers
```

```
Out[68]: array([ 5, 10, 15, 20])
```

```
In [25]: 2 ** numbers
```

```
Out[25]: array([ 2,  4,  8, 16])
```

```
In [26]: 10 + numbers
```

```
Out[26]: array([11, 12, 13, 14])
```

Operações entre *Arrays*

```
In [31]: numbers2 = np.arange(5,9)
```

```
In [32]: numbers2
```

```
Out[32]: array([5, 6, 7, 8])
```

```
In [33]: numbers * numbers2
```

```
Out[33]: array([ 5, 12, 21, 32])
```

```
In [34]: numbers + numbers2
```

```
Out[34]: array([ 6,  8, 10, 12])
```

Operações

- Deve-se tomar cuidado com o operador `*`
- Mesmo que sua estrutura seja de matriz, ele irá considerar como se fosse um vetor para realizar a multiplicação (já que o operador para multiplicação de matrizes é o `“.”`)

```
In [82]: m1 = np.array([[2,1],[1,2]])  
In [83]: m1  
Out[83]: array([[2, 1],  
               [1, 2]])  
  
In [84]: inversa = np.linalg.inv(m1)  
In [85]: inversa  
Out[85]: array([[ 0.66666667, -0.33333333],  
               [-0.33333333,  0.66666667]])  
  
In [86]: m1 * inversa  
Out[86]: array([[ 1.33333333, -0.33333333],  
               [-0.33333333,  1.33333333]])  
  
In [87]: m1.dot(inversa)  
Out[87]: array([[1., 0.],  
               [0., 1.]])
```

Comparações entre *Arrays*

```
In [36]: numbers < numbers2
```

```
Out[36]: array([ True,  True,  True,  True])
```

```
In [37]: numbers != numbers2
```

```
Out[37]: array([ True,  True,  True,  True])
```

```
In [39]: numbers == numbers2
```

```
Out[39]: array([False, False, False, False])
```

Transposição

```
In [15]: grades
```

```
Out[15]: array([[ 87,  96,  70],  
               [100,  87,  90],  
               [ 94,  77,  90],  
               [100,  81,  82]])
```

```
In [16]: #Transpondo a matriz  
grades.T
```

```
Out[16]: array([[ 87, 100,  94, 100],  
               [ 96,  87,  77,  81],  
               [ 70,  90,  90,  82]])
```

```
In [17]: #Idem ao anterior  
grades.transpose()
```

```
Out[17]: array([[ 87, 100,  94, 100],  
               [ 96,  87,  77,  81],  
               [ 70,  90,  90,  82]])
```

Sumarização

```
In [52]: integers
```

```
Out[52]: array([[1, 2, 3],  
               [4, 5, 6]])
```

```
In [53]: integers.max()
```

```
Out[53]: 6
```

```
In [54]: integers.mean()
```

```
Out[54]: 3.5
```

Sumarização

```
In [55]: #Tirando a média por linha  
         integers.mean(axis=0)
```

```
Out[55]: array([2.5, 3.5, 4.5])
```

```
In [56]: #Tirando a média por coluna  
         integers.mean(axis=1)
```

```
Out[56]: array([2., 5.])
```

```
In [57]: integers.mean(axis=1)[0]
```

```
Out[57]: 2.0
```

Gravação de Arquivos

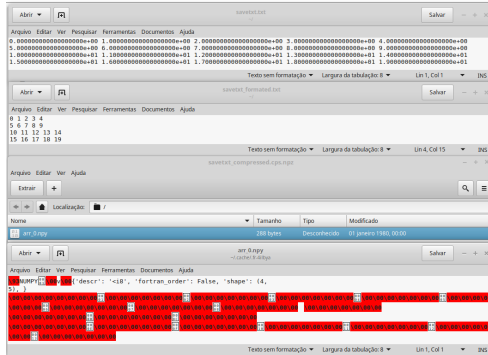
- O módulo NumPy também possui utilitários para fazer gravações e leituras de arrays
- No caso da leitura, após feita, já é gerado um objeto de array do NumPy
- É possível salvar em modo texto, modo binário e binário comprimido
- Também é possível especificar delimitadores dos elementos de um array, cabeçalhos e rodapés no caso do salvamento em modo texto

Gravação de Arquivos

```
1 np.savetxt('savetxt.txt', array1)
```

```
1 np.savetxt('savetxt_formatted.txt', array1, fmt='%d')
```

```
1 np savez_compressed('savetxt_compressed.cps', array1)
```



Leitura de Arquivos

- Assim como na gravação, também há métodos para se fazer a leitura de arrays em modo texto, binário ou binário comprimido

```
In [63]: 1 array2 = np.loadtxt('savetxt.txt', dtype=np.int16)
          2 array2
```

```
Out[63]: array([[ 0,  1,  2,  3,  4],
                 [ 5,  6,  7,  8,  9],
                 [10, 11, 12, 13, 14],
                 [15, 16, 17, 18, 19]], dtype=int16)
```

```
In [66]: 1 array2 = np.load('savetxt_compressed.cps.npz')
          2 array2
```

```
Out[66]: <numpy.lib.npyio.NpzFile at 0x7fbd59265208>
```

```
In [67]: 1 array2.files
```

```
Out[67]: ['arr_0']
```

```
In [68]: 1 array2['arr_0']
```

```
Out[68]: array([[ 0,  1,  2,  3,  4],
                 [ 5,  6,  7,  8,  9],
                 [10, 11, 12, 13, 14],
                 [15, 16, 17, 18, 19]])
```

Concatenando Arrays

- É possível utilizar o método `concat` para concatenar *arrays*
- Por padrão, a concatenação é feita feita verticalmente, porém, é possível alterar o eixo da concatenação

```
In [85]: 1 arr1 = np.array([[1,2,3],[4,5,6]])  
2 arr2 = np.array([[7,8,9],[10,11,12]])
```

```
In [86]: 1 arr1
```

```
Out[86]: array([[1, 2, 3],  
               [4, 5, 6]])
```

```
In [87]: 1 arr2
```

```
Out[87]: array([[ 7,  8,  9],  
               [10, 11, 12]])
```

```
In [88]: 1 np.concatenate((arr1,arr2))
```

```
Out[88]: array([[ 1,  2,  3],  
               [ 4,  5,  6],  
               [ 7,  8,  9],  
               [10, 11, 12]])
```

```
In [89]: 1 np.concatenate((arr1,arr2), axis=0)
```

```
Out[89]: array([[ 1,  2,  3],  
               [ 4,  5,  6],  
               [ 7,  8,  9],  
               [10, 11, 12]])
```

```
In [90]: 1 np.concatenate((arr1,arr2), axis=1)
```

```
Out[90]: array([[ 1,  2,  3,  7,  8,  9],  
               [ 4,  5,  6, 10, 11, 12]])
```

Concatenando Arrays

- Também é possível utilizar o método `stack`, ou os métodos `vstack` e `hstack` para realizar as concatenações verticalmente e horizontalmente respectivamente

```
In [91]: 1 arr1
Out[91]: array([[1, 2, 3],
               [4, 5, 6]])

In [92]: 1 arr2
Out[92]: array([[ 7,  8,  9],
               [10, 11, 12]])

In [93]: 1 np.stack((arr1,arr2))
Out[93]: array([[[ 1,  2,  3],
                 [ 4,  5,  6]],

               [[ 7,  8,  9],
                [10, 11, 12]])

In [98]: 1 np.vstack((arr1,arr2))
Out[98]: array([[ 1,  2,  3],
               [ 4,  5,  6],
               [ 7,  8,  9],
               [10, 11, 12]])

In [99]: 1 np.hstack((arr1,arr2))
Out[99]: array([[ 1,  2,  3,  7,  8,  9],
               [ 4,  5,  6, 10, 11, 12]])
```

Concatenando Arrays

- Pode-se também utilizar o método `append` para fazer concatenações, porém, há distorções nos *shapes* originais dos *arrays*

```
In [100]: 1 arr1
```

```
Out[100]: array([[1, 2, 3],  
                [4, 5, 6]])
```

```
In [101]: 1 arr2
```

```
Out[101]: array([[ 7,  8,  9],  
                [10, 11, 12]])
```

```
In [102]: 1 np.append(arr1, arr2)
```

```
Out[102]: array([ 1,  2,  3,  4,  5,  6,  7,  8,  9,  
                10, 11, 12])
```

```
In [103]: 1 np.append(arr1, arr2, axis=1)
```

```
Out[103]: array([[ 1,  2,  3,  7,  8,  9],  
                [ 4,  5,  6, 10, 11, 12]])
```

Dividindo Arrays

- Pode-se utilizar o método *vsplit* para realizar segmentações verticais em um *array*
- O método aceita tanto um número fixo de segmentos quanto uma lista, a qual indicará o intervalo de índices em cada divisão

```
In [104]: 1 arr = np.arange(20).reshape(4,5)
```

```
In [105]: 1 arr
```

```
Out[105]: array([[ 0,  1,  2,  3,  4],  
                [ 5,  6,  7,  8,  9],  
                [10, 11, 12, 13, 14],  
                [15, 16, 17, 18, 19]])
```

```
In [108]: 1 np.vsplit(arr,2)
```

```
Out[108]: [array([[0, 1, 2, 3, 4],  
                [5, 6, 7, 8, 9]]),  
          array([[10, 11, 12, 13, 14],  
                [15, 16, 17, 18, 19]])]
```

```
In [110]: 1 np.vsplit(arr,[1,3])
```

```
Out[110]: [array([[0, 1, 2, 3, 4]]),  
          array([[ 5,  6,  7,  8,  9],  
                [10, 11, 12, 13, 14]]),  
          array([[15, 16, 17, 18, 19]])]
```

Dividindo Arrays

- Da mesma forma que o `vsplit`, pode-se utilizar o `hsplit` para realizar sementações verticais em um *array*

```
In [112]: 1 arr
```

```
Out[112]: array([[ 0,  1,  2,  3,  4],  
                [ 5,  6,  7,  8,  9],  
                [10, 11, 12, 13, 14],  
                [15, 16, 17, 18, 19]])
```

```
In [117]: 1 np.hsplit(arr, [1,2])
```

```
Out[117]: [array([[ 0],  
                [ 5],  
                [10],  
                [15]]),  
          array([[ 1],  
                [ 6],  
                [11],  
                [16]]),  
          array([[ 2,  3,  4],  
                [ 7,  8,  9],  
                [12, 13, 14],  
                [17, 18, 19]])]
```

Material Complementar

- Wikipedia – NumPy

<https://en.wikipedia.org/wiki/NumPy>

- Numpy — Array Creation

<https://www.geeksforgeeks.org/numpy-array-creation/>

- `numpy.loadtxt`

<https://docs.scipy.org/doc/numpy-1.13.0/reference/generated/numpy.loadtxt.html#numpy.loadtxt>

Material Complementar

- Learn NUMPY in 5 minutes - BEST Python Library!

<https://www.youtube.com/watch?v=xECXZ3ty0No&t=4s>

- Python NumPy Tutorial for Beginners

<https://www.youtube.com/watch?v=QUT1VHiLmmI>

- Quickstart tutorial

<https://numpy.org/doc/stable/user/quickstart.html>

- NumPy Joining Array

https://www.w3schools.com/python/numpy_array_join.asp

Imagem do Dia

**C++ and JAVA developer: learning
PYTHON**



**PYTHON developer: learning JAVA and
C++**



Tópicos em Inteligência Artificial

<http://ava.ufms.br/>

Rafael Geraldeli Rossi
rafael.g.rossi@ufms.br